

Jak otworzyć plik Parquet na Macu

Instrukcja od zera — bez wcześniejszej znajomości Pythona i terminala

Cel. Po wykonaniu instrukcji otworzysz plik .parquet, sprawdzisz jego kolumny i zobaczysz pierwsze rekordy. Nie musisz wcześniej znać Pythona ani SQL.

Najpierw cztery pojęcia

Parquet: format pliku z danymi — podobnie jak CSV lub Excel, ale lepiej przystosowany do dużych zbiorów.

Terminal: wbudowane w macOS okno, w którym uruchamiasz polecenia. Nie trzeba go instalować.

Python: program potrzebny do wykonania kodu z tej instrukcji. Jego instalujemy.

Biblioteka: dodatek do Pythona. W tej instrukcji używamy PyArrow, Polars i DuckDB.

Ważne. PyArrow, Polars i DuckDB to trzy alternatywne sposoby otwierania tego samego pliku. Nie musisz używać wszystkich. Dla dużych danych i wyszukiwania trendów rekomendowany jest DuckDB.

Czego potrzebujesz

Komputer: Mac z systemem macOS i kontem pozwalającym instalować aplikacje.

Internet: potrzebny podczas instalacji Pythona i bibliotek.

Plik: rozpakowany plik z rozszerzeniem .parquet.

Czas: około 10–15 minut przy pierwszej konfiguracji.

KROK 1 | Pobierz i zainstaluj Pythona

1. Otwórz przeglądarkę internetową.
2. Wejdź na oficjalną stronę: <https://www.python.org/downloads/macos/>
3. W sekcji najnowszej stabilnej wersji kliknij macOS installer. Pobierze się plik kończący się na .pkg.
4. Otwórz pobrany plik .pkg i przejdź przez instalator: Dalej / Continue, Zgadzam się / Agree, Zainstaluj / Install.
5. System może poprosić o hasło do konta na Macu albo użycie Touch ID. To zgoda na instalację programu, a nie hasło do pliku ZIP.
6. Po zakończeniu otwórz Finder → Aplikacje → Python 3.14 i uruchom dwuklikiem plik Install Certificates.command.
7. Gdy w otwartym oknie pojawi się update complete, zamknij je.

Nie instaluj Terminala. Terminal jest już elementem macOS. Instalujesz wyłącznie Pythona i jego dodatki.

Apple Silicon i Intel. Aktualny instalator universal2 z python.org działa na obsługiwanych Macach zarówno z procesorem Apple, jak i Intel.

KROK 2 | Uruchom Terminal i sprawdź Pythona

1. Naciśnij jednocześnie Command (⌘) i spację, aby otworzyć Spotlight.
2. Wpisz Terminal.
3. Uruchom aplikację Terminal.
4. W oknie Terminala, przy linii kończącej się zwykle znakiem % albo \$, wpisz dokładnie:

```
python3 --version
```

Uwaga na zapis. Ma być python3 bez spacji, potem jedna spacja oraz dwie kreski przed słowem version:
python3 --version.

Jeżeli polecenie nie działa, zamknij Terminal, otwórz go ponownie i jeszcze raz wpisz python3 --version.

Prawidłowy wynik wygląda podobnie do:

```
Python 3.14.7
```

KROK 3 | Zainstaluj biblioteki

Pozostań w Terminalu. Przy linii kończącej się znakiem % albo \$ wklej:

```
python3 -m pip install pyarrow pandas duckdb
```

Naciśnij Enter i poczekaj. Instalacja może wyświetlić wiele linii tekstu.

Prawidłowe zakończenie. Na końcu pojawi się komunikat Successfully installed oraz ponownie zwykła linia Terminala.

Jeżeli pojawi się pytanie. Wpisz y i naciśnij Enter. Żółte komunikaty WARNING zwykle są ostrzeżeniem, a nie przerwaniem instalacji.

KROK 4 | Przygotuj plik Parquet

1. Pobierz archiwum ZIP przekazane przez organizatora. W archiwum znajdują się dwa pliki: datasprint_sample_data.zip o rozmiarze około 18 GB oraz datasprint_full_data.zip o rozmiarze około 87 GB. Jeśli nie masz wystarczająco dużo miejsca na laptopie, aby pobrać datasprint_full_data.zip, pobierz i użyj mniejszego pliku. Korzystanie z mniejszego pliku nie będzie mieć wpływu na ocenę i jakość rozwiązania, został on dodany dla wygody uczestników.
2. Otwórz Finder → Pobrane i kliknij archiwum ZIP dwa razy. Jeżeli pojawi się pytanie o hasło, wpisz hasło otrzymane od organizatora.
3. Odszukaj wypakowany plik kończący się rozszerzeniem .parquet.
4. Przenieś ten plik bezpośrednio do folderu Pobrane.
5. Na potrzeby tej instrukcji zmień jego nazwę na:

```
dane.parquet
```

Sprawdź rozszerzenie. Pełna nazwa musi brzmieć dane.parquet, a nie dane.parquet.zip ani dane.parquet.txt.

KROK 5 | Wejdź do Pythona

W Terminalu wpisz:

```
python3
```

Po chwili zobaczysz znak:

```
>>>
```

To kluczowe rozróżnienie. Przy zwykłej linii Terminala zakończonej % albo \$ wpisujesz polecenia, np. python3 lub instalację bibliotek. Przy >>> wpisujesz kod Pythona, np. import pandas as pd.

KROK 6 | Ustaw lokalizację pliku

Przy znaku >>> wklej kolejno poniższe dwie linie. Po każdej naciśnij Enter:

```
from pathlib import Path
file_path = str(Path.home() / "Downloads" / "dane.parquet")
```

Sprawdź, jaką lokalizację ustawił Python:

```
print(file_path)
```

Powinna pojawić się ścieżka podobna do:

```
/Users/TwojaNazwa/Downloads/dane.parquet
```

Jeżeli pojawi się FileNotFoundError. Python nie znalazł pliku. Sprawdź, czy dane.parquet rzeczywiście znajduje się bezpośrednio w folderze Pobrane i czy nazwa jest identyczna.

KROK 7 | Wybierz sposób otwarcia pliku

Poniższe warianty są niezależne. Możesz użyć jednego albo przetestować wszystkie trzy.

Wariant A — PyArrow: sprawdzenie technicznej struktury

Przy znaku >>> wpisz kolejno:

```
import os
import pyarrow as pa
import pyarrow.parquet as pq
parquet_path = os.path.expanduser(file_path)
pf = pq.ParquetFile(parquet_path)
print("Shape:", (pf.metadata.num_rows, pf.metadata.num_columns))
batch = next(pf.iter_batches(batch_size=10))
table = pa.Table.from_batches([batch])
display(table.to_pandas())
```

Pierwsze polecenie pokazuje liczbę wierszy i kolumn tabeli. Ostatnie pokazuje maksymalnie 10 pierwszych rekordów. PyArrow pozwala czytać Parquet partiami, dzięki czemu nie trzeba ładować całego pliku do pamięci RAM.

Wariant B — Polars: dane w postaci tabeli

Przy znaku >>> wpisz kolejno:

```
import os
import polars as pl
```

```
parquet_path = os.path.expanduser(file_path)
lf = pl.scan_parquet(parquet_path)
print(lf.limit(20).collect())
print(lf.collect_schema())
```

limit(10) pokazuje pierwszych 10 rekordów. collect_schema pokazuje nazwy kolumn i typy danych.

Duży plik. Unikaj pandas, bo może wczytać cały zbiór do RAM. Przy bardzo dużych danych użyj najpierw Polars lazy lub DuckDB.

Wariant C — DuckDB: rekomendowany dla dużych zbiorów

Przy znaku >>> wpisz kolejno:

```
import duckdb
duckdb.sql(f"SELECT * FROM '{file_path}' LIMIT 10").show()
```

LIMIT 10 oznacza: pokaż tylko 10 rekordów. DuckDB nie musi wyświetlać ani przekazywać do Pandas całego miliona wierszy.

Aby policzyć wszystkie rekordy bez ich wyświetlania, wpisz:

```
duckdb.sql(f"SELECT COUNT(*) AS liczba_rekordow FROM '{file_path}').show()
```

Aby zobaczyć nazwy kolumn i ich typy, wpisz:

```
duckdb.sql(f"DESCRIBE SELECT * FROM '{file_path}').show()
```

Opcjonalnie — DuckDB bez uruchamiania Pythona

Ten wariant odpowiada części CLI z instrukcji Visa. Wymaga programu Homebrew. Jeśli go nie masz, możesz bez problemu zostać przy wariacie DuckDB w Pythonie opisanym wyżej.

Najpierw wyjdź z Pythona poleceniem exit(). Następnie sprawdź w Terminalu:

```
brew --version
```

Jeżeli pojawi się numer wersji Homebrew, wpisz:

```
brew install duckdb
```

Po instalacji możesz podejrzeć 10 rekordów bezpośrednio z Terminala:

```
duckdb -c "SELECT * FROM '$HOME/Downloads/dane.parquet' LIMIT 10;"
```

Jeżeli widzisz command not found: brew. Homebrew nie jest zainstalowany. Ten wariant jest opcjonalny — wróć do DuckDB uruchamianego w Pythonie.

KROK 8 | Zakończ pracę

Jeśli nadal widzisz znak >>>, wyjdź z Pythona i wróć do zwykłej linii Terminala, wpisując:

```
exit()
```

KROK 9 | Jak analizować większy zbiór

Przy milionie rekordów nie próbuj oglądać wszystkich wierszy. Zamiast tego zadawaj zbiorowi konkretne pytania: ile jest rekordów, jakie są najczęstsze kategorie, jak zmieniają się wartości w czasie albo gdzie pojawiają się nietypowe skoki.

Najczęstsze wartości w wybranej kolumnie

```
duckdb.sql(f"""
SELECT kategoria, COUNT(*) AS liczba
FROM '{file_path}'
GROUP BY kategoria
ORDER BY liczba DESC
LIMIT 20
""").show()
```

Zastąp słowo kategoria prawdziwą nazwą kolumny z pliku.

Trend miesięczny

```
trend = duckdb.sql(f"""
SELECT
    date_trunc('month', CAST(data AS DATE)) AS miesiac,
    COUNT(*) AS liczba_rekordow,
    SUM(kwota) AS laczna_wartosc
FROM '{file_path}'
GROUP BY 1
ORDER BY 1
""").df()
print(trend)
```

Nazwy data oraz kwota są przykładowe. Przed użyciem zastąp je nazwami istniejącymi w otrzymanym zbiorze.

Zasada dla dużych danych. Nie używaj `print(df.to_string())` ani `SELECT *` bez `LIMIT`. Najpierw sprawdź kolumny, później filtruj i grupuj dane, a dopiero mały wynik przenoś do Pandas, Excela lub wykresu.

KROK 10 | Najczęstsze problemy

„command not found: import”: Kod Pythona został wklejony przy zwykłej linii Terminala. Wpisz python3, poczekaj na >>> i dopiero wtedy wklej import.

„No module named...”: Brakuje biblioteki. Wpisz exit(), a w Terminalu ponownie wykonaj python3 -m pip install pyarrow pandas duckdb.

„FileNotFoundError”: Nazwa pliku albo jego położenie nie zgadza się z file_path. Sprawdź folder Pobrane i nazwę dane.parquet.

Terminal pokazuje dużo tekstu z błędem: Przeczytaj ostatnią linię. Zwykle problemem jest zła lokalizacja pliku, brak biblioteki albo wpisanie kodu w niewłaściwym miejscu.

Terminal przestał odpowiadać: Nie próbuj drukować całego zbioru. Zamknij okno, uruchom Terminal ponownie i użyj DuckDB z LIMIT.

Szybka checklista

- 1: Python odpowiada na python3 --version.
- 2: Biblioteki zostały zainstalowane bez czerwonego błędu.
- 3: Plik dane.parquet znajduje się bezpośrednio w folderze Pobrane.
- 4: Kod import... jest wpisywany dopiero przy znaku >>>.
- 5: Przy dużym zbiorze używany jest LIMIT albo agregacja, a nie wyświetlanie całości.

Źródła techniczne

Oficjalna dokumentacja Pythona dla macOS: docs.python.org/3/using/mac.html

Oficjalne instalatory dla macOS: python.org/downloads/macos/