

Jak otworzyć plik Parquet na Windowsie

Instrukcja od zera — bez wcześniejszej znajomości Pythona i terminala

Cel. Po wykonaniu instrukcji otworzysz plik .parquet, sprawdzisz jego kolumny i zobaczysz pierwsze rekordy. Nie musisz wcześniej znać Pythona ani SQL.

Najpierw cztery pojęcia

Parquet: format pliku z danymi — podobnie jak CSV lub Excel, ale lepiej przystosowany do dużych zbiorów.

PowerShell: wbudowane w Windows okno, w którym uruchamiasz polecenia. Nie trzeba go instalować.

Python: program potrzebny do wykonania kodu z tej instrukcji. Jego instalujemy.

Biblioteka: dodatek do Pythona. W tej instrukcji używamy PyArrow, Polars i DuckDB.

Ważne. PyArrow, Polars i DuckDB to trzy alternatywne sposoby otwierania tego samego pliku. Nie musisz używać wszystkich. Dla dużych danych i wyszukiwania trendów rekomendowany jest DuckDB.

Czego potrzebujesz

Komputer: Windows 10 albo Windows 11.

Internet: potrzebny podczas instalacji Pythona i bibliotek.

Plik: rozpakowany plik z rozszerzeniem .parquet.

Czas: około 10–15 minut przy pierwszej konfiguracji.

KROK 1 | Pobierz i zainstaluj Pythona

1. Otwórz przeglądarkę internetową.
2. Wejdź na oficjalną stronę: <https://www.python.org/downloads/>
3. Pobierz aktualny instalator Pythona dla Windows i uruchom pobrany plik.
4. Jeśli pojawi się pomocnik konfiguracji, odpowiadaj:

Long paths / ścieżki dłuższe niż 260 znaków: wpisz y i naciśnij Enter.

Add commands directory to PATH: wpisz y i naciśnij Enter.

View online help: wpisz n albo naciśnij sam Enter.

5. Po zakończeniu konfiguracji zamknij instalator i uruchom ponownie komputer.

Nie instaluj PowerShella. PowerShell jest już elementem Windows. Instalujesz wyłącznie Pythona.

KROK 2 | Uruchom PowerShell i sprawdź Pythona

1. Kliknij przycisk Start.
2. Wpisz PowerShell.
3. Uruchom aplikację Windows PowerShell lub PowerShell.
4. W czarnym oknie, przy linii zaczynającej się od PS, wpisz dokładnie:

```
py --version
```

Uwaga na spacje. Ma być jedna spacja po py oraz dwie kreski bez spacji przed słowem version: py --version.

Jeśli Python zacznie się teraz automatycznie pobierać lub aktualizować, poczekaj do końca. Następnie ponownie wpisz py --version.

Prawidłowy wynik wygląda podobnie do:

```
Python 3.14.7
```

KROK 3 | Zainstaluj biblioteki

Pozostań w PowerShellu. Przy linii zaczynającej się od PS wklej:

```
py -m pip install pyarrow pandas duckdb
```

Naciśnij Enter i poczekaj. Instalacja może wyświetlić wiele linii tekstu.

Prawidłowe zakończenie. Na końcu pojawi się komunikat Successfully installed oraz ponownie linia rozpoczynająca się od PS.

Żółte ostrzeżenia. Komunikat WARNING dotyczący PATH nie blokuje odczytu pliku i w tej instrukcji można go pominąć.

KROK 4 | Przygotuj plik Parquet

1. Pobierz archiwum ZIP przekazane przez organizatora. W archiwum znajdują się dwa pliki: datasprint_sample_data.zip o rozmiarze około 18 GB oraz datasprint_full_data.zip o rozmiarze około 87 GB. Jeśli nie masz wystarczająco dużo miejsca na laptopie aby pobrać datasprint_full_data.zip, pobierz i użyj mniejszego pliku. Korzystanie z mniejszego pliku nie będzie mieć wpływu na ocenę i jakość rozwiązania, został on dodany dla wygody uczestników.
2. Rozpakuj archiwum. Jeżeli pojawi się pytanie o hasło, wpisz hasło otrzymane od organizatora.
3. Odszukaj wypakowany plik kończący się rozszerzeniem .parquet.
4. Przenieś ten plik bezpośrednio do folderu Pobrane.
5. Na potrzeby tej instrukcji zmień jego nazwę na:

```
dane.parquet
```

Sprawdź rozszerzenie. Pełna nazwa musi brzmieć dane.parquet, a nie dane.parquet.zip ani dane.parquet.txt.

KROK 5 | Wejdź do Pythona

W PowerShellu wpisz:

```
py
```

Po chwili zobaczysz znak:

```
>>>
```

To kluczowe rozróżnienie. Przy PS C:\...> wpisujesz komendy PowerShella, np. py lub instalację bibliotek. Przy >>> wpisujesz kod Pythona, np. import pandas as pd.

KROK 6 | Ustaw lokalizację pliku

Przy znaku >>> wklej kolejno poniższe dwie linie. Po każdej naciśnij Enter:

```
from pathlib import Path
file_path = str(Path.home() / "Downloads" / "dane.parquet")
```

Sprawdź, jaką lokalizację ustawił Python:

```
print(file_path)
```

Powinna pojawić się ścieżka podobna do:

```
C:\Users\TwojaNazwa\Downloads\dane.parquet
```

Jeżeli pojawi się FileNotFoundError. Python nie znalazł pliku. Sprawdź, czy dane.parquet rzeczywiście znajduje się bezpośrednio w folderze Pobrane i czy nazwa jest identyczna.

KROK 7 | Wybierz sposób otwarcia pliku

Poniższe warianty są niezależne. Możesz użyć jednego albo przetestować wszystkie trzy.

Wariant A — PyArrow: sprawdzenie technicznej struktury

Przy znaku >>> wpisz kolejno:

```
import os
import pyarrow as pa
import pyarrow.parquet as pq
parquet_path = os.path.expanduser(file_path)
pf = pq.ParquetFile(parquet_path)
print("Shape:", (pf.metadata.num_rows, pf.metadata.num_columns))
batch = next(pf.iter_batches(batch_size=10))
table = pa.Table.from_batches([batch])
display(table.to_pandas())
```

Pierwsze polecenie pokazuje liczbę wierszy i kolumn tabeli. Ostatnie pokazuje maksymalnie 10 pierwszych rekordów. PyArrow pozwala czytać Parquet partiami, dzięki czemu nie trzeba ładować całego pliku do pamięci RAM.

Wariant B — Polars: dane w postaci tabeli

Przy znaku >>> wpisz kolejno:

```
import os
import polars as pl
```

```
parquet_path = os.path.expanduser(file_path)
lf = pl.scan_parquet(parquet_path)
print(lf.limit(20).collect())
print(lf.collect_schema())
```

limit(10) pokazuje pierwszych 10 rekordów. collect_schema pokazuje nazwy kolumn i typy danych.

Duży plik. Unikaj pandas, bo może wczytać cały zbiór do RAM. Przy bardzo dużych danych użyj najpierw Polars lazy lub DuckDB.

Wariant C — DuckDB: rekomendowany dla dużych zbiorów

Przy znaku >>> wpisz kolejno:

```
import duckdb
file_path_sql = file_path.replace("\\", "/")
duckdb.sql(f"SELECT * FROM '{file_path_sql}' LIMIT 10").show()
```

LIMIT 10 oznacza: pokaż tylko 10 rekordów. DuckDB nie musi wyświetlać ani przekazywać do Pandas całego miliona wierszy.

Aby policzyć wszystkie rekordy bez ich wyświetlania, wpisz:

```
duckdb.sql(f"SELECT COUNT(*) AS liczba_rekordow FROM '{file_path_sql}').show()
```

Aby zobaczyć nazwy kolumn i ich typy, wpisz:

```
duckdb.sql(f"DESCRIBE SELECT * FROM '{file_path_sql}').show()
```

KROK 8 | Zakończ pracę

Aby wyjść z Pythona i wrócić do PowerShella, wpisz przy znaku >>>:

```
exit()
```

KROK 9 | Jak analizować większy zbiór

Przy milionie rekordów nie próbuj oglądać wszystkich wierszy. Zamiast tego zadawaj zbiorowi konkretne pytania: ile jest rekordów, jakie są najczęstsze kategorie, jak zmieniają się wartości w czasie albo gdzie pojawiają się nietypowe skoki.

Najczęstsze wartości w wybranej kolumnie

```
duckdb.sql(f"""
SELECT kategoria, COUNT(*) AS liczba
FROM '{file_path_sql}'
GROUP BY kategoria
ORDER BY liczba DESC
LIMIT 20
""").show()
```

Zastąp słowo kategoria prawdziwą nazwą kolumny z pliku.

Trend miesięczny

```
trend = duckdb.sql(f"""
SELECT
    date_trunc('month', CAST(data AS DATE)) AS miesiac,
    COUNT(*) AS liczba_rekordow,
    SUM(kwota) AS laczna_wartosc
FROM '{file_path_sql}'
GROUP BY 1
ORDER BY 1
""").df()
print(trend)
```

Nazwy data oraz kwota są przykładowe. Przed użyciem zastąp je nazwami istniejącymi w otrzymanym zbiorze.

Zasada dla dużych danych. Nie używaj `print(df.to_string())` ani `SELECT *` bez `LIMIT`. Najpierw sprawdź kolumny, później filtruj i grupuj dane, a dopiero mały wynik przenoś do Pandas, Excela lub wykresu.

KROK 10 | Najczęstsze problemy

„import is not recognized”: Kod Pythona został wklejony przy PS. Wpisz py, poczekaj na >>> i dopiero wtedy wklej import.

„No module named...”: Brakuje biblioteki. Wpisz exit(), a przy PS ponownie wykonaj py -m pip install pyarrow pandas duckdb.

„FileNotFoundError”: Nazwa pliku albo jego położenie nie zgadza się z file_path. Sprawdź folder Pobrane i nazwę dane.parquet.

PowerShell pokazuje dużo czerwonego tekstu: Przeczytaj ostatnią linię błędu. Zwykle problemem jest zła lokalizacja pliku, brak biblioteki albo wpisanie kodu w niewłaściwym miejscu.

Terminal przestał odpowiadać: Nie próbuj drukować całego zbioru. Zamknij okno, uruchom PowerShell ponownie i użyj DuckDB z LIMIT.

Szybka checklista

- 1: Python odpowiada na py --version.
- 2: Biblioteki zostały zainstalowane bez czerwonego błędu.
- 3: Plik dane.parquet znajduje się bezpośrednio w folderze Pobrane.
- 4: Kod import... jest wpisywany dopiero przy znaku >>>.
- 5: Przy dużym zbiorze używany jest LIMIT albo agregacja, a nie wyświetlanie całości.

Źródła techniczne

Oficjalna dokumentacja Pythona dla Windows: docs.python.org/3/using/windows.html

Oficjalne pliki instalacyjne: python.org/downloads/